

SewerStudio 4.0

KI-Training — Vollstaendiges Code-Audit

Parameter	Wert
Datum	11. April 2026
Scope	Self-Training, YOLO-Retrain, LoRA, Knowledge Base, Benchmark
Methode	6 parallele Code-Analyse-Agenten + Live-Runtime-Check
Reviews	Claude Opus (statisch) + Gemini (Architektur) + ChatGPT (Bugs) + Live-Audit
Hardware	Intel Core Ultra 9 285K, ASUS RTX 5090 32GB, 64GB DDR5
Projekt	Solo-Entwickler, keine kommerzielle Nutzung

Go/No-Go Bewertung:

No-Go fuer Produktion — Sidecar im Maintenance-Mode blockiert, 0 BBox-Daten, Benchmark nicht aktiv. Architektur und Konzept sind exzellent, Implementierung hat punktuelle Thread-Sicherheits- und Datenqualitaets-Luecken.

Inhaltsverzeichnis

1. Gesamtbewertung
2. Live-Runtime-Status
3. Severity-Uebersicht
4. BLOCKER-Findings (12)
5. HIGH-Findings (18)
6. MEDIUM-Findings (16)
7. Sicherheits-Findings
8. Test-Abdeckung
9. Konsolidierung: 4 Reviews im Vergleich
10. Empfohlene Prioritaeten
11. Positiv-Bewertung

1. Gesamtbewertung

Kategorie	Bewertung	Details
Architektur und Konzept	Exzellent	MLOps-Level, Thin-AI sauber durchgesetzt
Datenintegritaet (Stores)	Gut	Atomic Writes, Backup-Rotation vorhanden
Fehlerbehandlung	Mittel	Viele Silent-Failures, fehlendes Logging
Thread-Sicherheit	Schwach	Mehrere Race Conditions und Deadlock-Risiken
Test-Abdeckung	Schwach	35+ kritische Klassen ohne Tests
Sidecar (Python)	Schwach	Guard-Luecken, Path Traversal, VRAM-Risiken
Trainingsqualitaet (Daten)	Ungenuegend	0 BBox-Samples, Benchmark nicht aktiv

2. Live-Runtime-Status (11.04.2026)

Direkter Health-Check gegen den laufenden Sidecar auf localhost:8100:

Komponente	Wert	Auswirkung
Sidecar Status	maintenance_reason = training	BLOCKIERT
GPU VRAM	0.54 GB allokiert (Modelle entladen)	Keine Inferenz
YOLO Modell	resolved_model_path = null	Kein Modell geladen
Custom Weights	custom_weights_present = false	Nur Basis-YOLO
Inferenz-Test	/detect/yolo liefert 409 Conflict	Komplett blockiert
Smoke-Test	161 Frames, 0 Detektionen	Keine Erkennung

Datenpunkt	Wert	Bewertung
Approved Samples	15.417	Status OK
HasBbox = true	0	Auto-Retrain unmoeiglich
SourceType VideoTimestamp	32	Zu wenig fuer YOLO
Benchmark-Set (aktiv)	1 Haltung	Braucht 20
Benchmark-Metriken	Datei fehlt	Kein Verlauf
Benchmark-Liste (tools/)	20 Haltungen	Nicht importiert

3. Severity-Uebersicht

Severity	Anzahl	Beschreibung
BLOCKER	12	Deadlocks, Race Conditions, fehlende Tests, Datenkorruption
HIGH	18	Deploy-Risiken, VRAM-Probleme, stille Datenverluste
MEDIUM	25+	Hardcoded Werte, fehlende Validierung, Code Smells
LOW	10+	Kosmetik, fehlende Kommentare, Edge Cases

4. BLOCKER-Findings (12)

[BLOCKER] B1: Deadlock Pause/Resume

Datei: VideoSelfTrainingOrchestrator.cs:188 BatchSelfTrainingOrchestrator.cs:564

Problem: Pause() ruft synchron Wait() auf SemaphoreSlim. Mehrere Threads haengen permanent bei nur einem Resume().

Fix: ManualResetEventSlim verwenden

[BLOCKER] B2: Race Condition TryConsumeBudget

Datei: SelfTrainingOrchestrator.cs:598

Problem: Stack-lokaler int per ref an parallele Threads. Volatile/CAS auf Stack bietet keine Thread-Sicherheit.

Fix: Interlocked.Decrement oder Klassenfeld

[BLOCKER] B3: Kein Mutex auf Retrain

Datei: YoloRetrainOrchestrator.cs:47

Problem: RunIfEligibleAsync ohne Semaphore. Parallele Retrains konkurrieren um VRAM und Manifest.

Fix: SemaphoreSlim(1,1) um Methode

[BLOCKER] B4: LoRA Guard nicht released

Datei: lora_training.py:313

Problem: Thread-Start-Fehler setzt _active_job_id zurueck, aber end_training_guard() fehlt.

Fix: Guard im Exception-Handler freigeben

[BLOCKER] B5: Race in _active_job_id

Datei: lora_training.py:281

Problem: Lock-Release vor begin_training_guard(). Zweiter Request kann durchkommen.

Fix: Lock ueber Guard-Acquisition halten

[BLOCKER] B6: Persist-Fehler nach Reload

Datei: YoloRetrainOrchestrator.cs:240

Problem: Reload gelingt, SaveManifest schlaegt fehl. Manifest zeigt auf altes Modell nach Neustart.

Fix: 2-Phase-Commit oder Fehler propagieren

[BLOCKER] B7: Embedding-Modell nicht geprueft

Datei: EmbeddingService.cs:44

Problem: Requests an Ollama ohne Model-Availability-Check. Batch-Indexierung laeuft leer.

Fix: Model-Check bei Startup

[BLOCKER] B8: SettingsStore nicht atomar

Datei: TrainingCenterSettingsStore.cs:34

Problem: File.Create + Serialize ohne Temp-File. Crash = korrupte Settings.

Fix: Atomic-Write-Pattern kopieren

[BLOCKER] B9: DifferenceAnalyzer ungetestet

Datei: DifferenceAnalyzer.cs (290 Zeilen)

Problem: Komplexer Greedy-Matching mit potenziellem Double-Assignment. Kein einziger Test.

Fix: Tests erstellen

[BLOCKER] B10: BenchmarkRunner ungetestet

Datei: BenchmarkRunner.cs:182

Problem: CodeMismatch als FN + FP gezaehlt. Doppelte Zaehlung bei gleichem Praefix moeglich.

Fix: Tests erstellen

[BLOCKER] B11: Keine CI/CD Pipeline

Datei: Kein .github/workflows/

Problem: Tests werden nie automatisch ausgefuehrt. Regressionen bleiben unentdeckt.

Fix: GitHub Actions einrichten

[BLOCKER] B12: FrameQualityFilter-State

Datei: FrameQualityFilter.cs:68

Problem: lastHash persistiert zwischen Videos. Erster Frame des neuen Videos faelschlich als Duplikat.

Fix: Auto-Reset zwischen Videos

5. HIGH-Findings (18)

#	Datei:Zeile	Problem
H1	SelfTrainingOrchestrator.cs:319	Auto-Approve prueft weder Meter noch Clock
H2	VideoSelfTrainingOrchestrator.cs:33	Race Condition auf volatile _isPaused
H3	BatchSelfTrainingOrchestrator.cs:634	Sidecar-Prozess nicht disposed
H4	BatchSelfTrainingOrchestrator.cs:754	History-Rotation ohne Lock
H5	DifferenceAnalyzer.cs:42	Greedy Assignment suboptimal bei nahen Befunden
H6	KnowledgeBaseManager.cs:59	Embedding-Fehler: Sample-State inkonsistent
H7	EmbeddingService.cs:54	Kein explizites Timeout fuer Ollama
H8	EmbeddingService.cs:70	JSON-Parsing ohne Bounds-Check
H9	KbDeduplicationService.cs:60	Leere Embeddings: Dedup deaktiviert
H10	KbEnrichmentService.cs:269	Caseld-Kollision bei gleicher Tageszeit
H11	RetrievalService.cs:50	Dimension-Mismatch still ignoriert
H12	RetrievalService.cs:186	Rohrmaterial nicht im SQL-Query
H13	SampleQualityGateService.cs:34	ZeroMeterCodes-Liste unvollstaendig
H14	YoloRetrainOrchestrator.cs:370	Pruning kann aktives Modell loeschen
H15	YoloRetrainOrchestrator.cs:410	Manifest-Korruption: stille leere Rueckgabe
H16	BenchmarkMetricsStore.cs:105	Regression-Threshold bricht bei avgF1=0
H17	lora_training.py:179	Keine VRAM-Pruefung vor LoRA-Training
H18	lora_training.py:345	Path Traversal in deploy-lora Endpoint

6. MEDIUM-Findings (Auswahl)

#	Datei:Zeile	Problem
M1	SelfTrainingComparisonService.cs:28	Hardcoded Toleranzen (Meter=1.0, Clock=1)
M2	SelfTrainingComparisonService.cs:180	Overly-breiter Praefix-Match
M3	SelfTrainingComparisonService.cs:277	Clock-Parsing: '12:00 Uhr' nicht unterstuetzt
M4	DifferenceAnalyzer.cs:156	Score-Bonus 0.075 bei fehlender Uhlage
M5	DifferenceAnalyzer.cs:284	Streckenschaden: Midpoint statt Range-Check
M6	KnowledgeBaseContext.cs:61	Fehlender Index auf Embeddings JOIN
M7	KnowledgeBaseContext.cs:43	PRAGMA foreign_keys nicht aktiviert
M8	TrainingCenterSettings.cs:50	PartialAutoApproveMinScore=0.60 zu niedrig
M9	KnowledgeBackupService.cs:176	Import-Rollback unvollstaendig
M10	PdfProtocolTableParser.cs:418	Kein explizites Encoding fuer pdftotext
M11	VideoSelfTrainingOrchestrator.cs:210	KillOrphanedFfmpeg killt ALLE ffmpeg > 5min
M12	BatchSelfTrainingOrchestrator.cs:537	PDF-Zuordnung per Contains statt exakt
M13	lora_training.py:156	Temp-Dateien nicht aufgeraemt bei Fehler
M14	lora_training.py:179	LoRA-Modell nicht explizit entladen
M15	training.py:149	Dataset-Quality-Check ignoriert fehlerhafte Labels
M16	yolo_wrapper.py:25	Globale Variablen ohne Lock bei Reload

7. Sicherheits-Findings

#	Severity	Datei:Zeile	Problem
S1	HIGH	lora_training.py:345	Path Traversal: deploy-lora akzeptiert beliebige Pfade
S2	MEDIUM	training.py:393	Base64-Image-Decoding ohne Groessenlimit (DoS)
S3	MEDIUM	SelfTrainingOrchestrator.cs:400	Few-Shot Code-Normalisierung: ArgumentOutOfRangeException bei kurzen Codes
S4	INFO	requirements.txt	Dependencies nicht gepinnt (>= statt ==)

8. Test-Abdeckung

Getestet (gut):

Klasse	Umfang	Qualitaet
SampleQualityGateService	277 Zeilen	Komprehensiv, alle Hard-Red Kriterien
VsaCodeResolver	233 Zeilen	Edge Cases, Umlaut-Handling, Clock-Normalisierung
QualityGateService	116 Zeilen	Alle 3 Ampelfarben, Gewichtungen
CalibrationMetrics	78 Zeilen	ECE-Berechnung, Bin-Grenzen
AutoApproval	102 Zeilen	Alle 5 Ablehnungskriterien

NICHT getestet (kritisch):

#	Klasse	Umfang	Risiko
1	DifferenceAnalyzer	290 Zeilen	Komplexer Matching-Algorithmus
2	BenchmarkRunner	226 Zeilen	Metrics-Aggregation
3	SelfTrainingOrchestrator	200+ Zeilen	Kernlogik Selbsttraining
4	VideoSelfTrainingOrchestrator	200+ Zeilen	Video-Pipeline
5	YoloRetrainOrchestrator	100+ Zeilen	YOLO-Retraining
6	QwenLoraOrchestrator	100+ Zeilen	LoRA Fine-Tuning
7	BenchmarkMetricsStore	100+ Zeilen	Regressions-Erkennung
8	SelfTrainingComparisonService	100+ Zeilen	Vergleichslogik
9	FrameQualityFilter	50+ Zeilen	Frame-Qualitaet
10	TrainingSamplesStore	300+ Zeilen	Datenintegritaet

9. Konsolidierung: 4 Reviews im Vergleich

Vier unabhaengige Perspektiven wurden zusammengefuehrt:

Aspekt	Gemini	ChatGPT	Claude Opus (statisch)	Live-Runtime
Architektur	Exzellent	Gut	Exzellent	--
Deploy-Reihenfolge	--	Problem	Bereits gefixt	Korrekt bestaetigt
Thread-Sicherheit	--	--	3 Blocker	--
BBox-Daten	--	--	--	0 von 15.417
Sidecar-Status	--	--	--	Blockiert (training)
Benchmark	--	--	--	1 statt 20
Test-Abdeckung	--	1 Fehler	35+ ungetestet	--
Auto-Approve	--	Risiko erkannt	Bestaetigt	Aggressiv

Korrigierte Findings:

Finding	Frueheres Audit	Tatsaechlich (verifiziert)
Deploy-Reihenfolge	Manifest VOR Reload (B6)	Bereits korrekt: Reload VOR Manifest
VSA im Sidecar	Test-Blocker	Bereits gefixt: 'Schadenscodes' statt 'VSA-Codes'

10. Empfohlene Prioritaeten

Phase 1: Sofort (Runtime-Blocker)

#	Aktion	Ziel	Aufwand
1	Sidecar neustarten	maintenance_reason auflösen	5 min
2	Benchmark-Set importieren	20 Haltungen aus tools/ aktivieren	10 min
3	Smoke-Test wiederholen	Detektionen > 0 verifizieren	15 min

Phase 2: Diese Woche (Code-Crashes)

#	Aktion	Ziel	Aufwand
4	Few-Shot Bug fixen	ArgumentOutOfRangeException bei kurzen Codes	10 min
5	LoRA Guard Release	end_training_guard() im Exception-Handler	5 min
6	Deadlock Pause/Resume	ManualResetEventSlim statt SemaphoreSlim	30 min
7	Retrain-Mutex	SemaphoreSlim(1,1) um RunIfEligibleAsync	10 min
8	SettingsStore atomar	Temp+Rename Pattern kopieren	20 min

Phase 3: Naechste Woche (Tests + Qualitaet)

#	Aktion	Ziel	Aufwand
9	DifferenceAnalyzerTests.cs	Matching-Algorithmus verifizieren	2h
10	BenchmarkRunnerTests.cs	Metrics-Berechnung verifizieren	1h
11	CI/CD Pipeline	GitHub Actions einrichten	1h
12	Auto-Approve konservativ	MinScore 0.80, AutoApprove=false	5 min
13	BBox-Pipeline planen	DINO+SAM fuer BBox-Generierung	4h

Phase 4: Mittelfristig (Robustheit)

#	Aktion	Ziel	Aufwand
14	Hardcoded Toleranzen	Konfigurierbar via Settings	2h
15	Hungarian Algorithm	Optimale Zuordnung statt Greedy	4h
16	KB-Performance	Index auf Embeddings, PRAGMA foreign_keys	1h
17	Path Traversal Fix	Pfad-Validierung in deploy-lora	30 min

11. Positiv-Bewertung

Die Gesamtarchitektur ist auf professionellem MLOps-Niveau. Die gefundenen Probleme sind Implementierungsdetails (Thread-Sicherheit, Edge Cases), keine Architekturmaengel.

Feature	Implementierung
Thin-AI Prinzip	Konsequent durchgesetzt via ArchitectureLayerGuardTests
Atomic Writes	TrainingSamplesStore: Temp-File + Validate + Rename + 3-Backup-Rotation
QualityGate-Ampel	Hard-Red Kriterien, gewichtete Issues, Batch-Evaluation
KnowledgeBase Dedup	Cosine-Similarity (0.92) + kanonische Signatur
Few-Shot RAG	nomic-embed-text Embeddings, Top-K Retrieval mit Hybrid-Scoring
Benchmark Pipeline	Regressions-Erkennung, Per-Code-F1, Zeitreihen-Speicher
Graceful Degradation	Sidecar-Ausfall: Fallback auf Qwen-Only
Per-Frame Timeout	Frame-Fehler ueberspringen statt Pipeline-Abbruch
Path-Traversal-Schutz	KnowledgeBackupService: GetFullPath + StartsWith-Check
Deploy-Reihenfolge	Write-After-Success: Reload vor Manifest (korrekt implementiert)

Erstellt von Claude Code Audit System. Vier unabhaengige Reviews konsolidiert: Claude Opus (statische Analyse), Gemini (Architektur-Review), ChatGPT (Bug-Finding), Live-Runtime-Audit.